

#### 5.2.4 Analiză matriceală

Majoritatea problemelor abordate matriceal presupun evaluarea unor proprietăți și testarea anumitor condiții cu privire la matricele componente. În continuare se prezintă prin exemple funcțiile Matlab pentru analiză matriceală.

##### a) Calculul determinantului asociat unei matrice

Cu funcția `det` se calculează determinantul unei matrice (pătrate) date cu instrucțiuni de forma `D=det (X)`, de exemplu:

```
>> X=[1 2 1;3 4 0;7 9 -8]
X =
     1     2     1
     3     4     0
     7     9    -8
>> D=det (X)
D =
    15
```

##### b) Calculul inversei unei matrice

Cu funcția `inv` se calculează inversa unei matrice date: `Y=inv (X)` adică  $Y=X^{-1}$ . Prin definiție, inversa unei matrici pătrate  $X$  este matricea  $X^{-1}$ , care satisface relația:

$$X \cdot X^{-1} = X^{-1} \cdot X = I,$$

unde  $I$  este matricea identitate. O matrice este inversabilă numai dacă este nesingulară, adică determinantul ei este diferit de zero.

De exemplu, pentru matricea  $X$  definită anterior se obține:

```
>> Y=inv (X)
Y =
   -2.1333    1.6667   -0.2667
    1.6000   -1.0000    0.2000
   -0.0667    0.3333   -0.1333
```

c) Rangul unei matrice

Cu funcția `rank` se calculează rangul unei matrice date, cu sintaxa `r=rank(X)` sau `r=rank(X,tol)`.

Rangul unei matrice este dimensiunea/ordinul celui mai mic determinant nenul, ce poate fi izolat în matricea respectivă. Se spune că o matrice nenulă are rangul  $k$ , dacă aceasta are un minor nenul de ordin  $k$ , iar toți minorii de ordin mai mare decât  $k$  (dacă există) sunt nuli. Rangul unei matrice se interpretează ca numărul de linii sau coloane liniar independente ale acesteia și este un număr scalar cu proprietatea:  $1 \leq k \leq \min(m,n)$ .

Apelată cu cea de-a doua sintaxă funcția `rank` returnează numărul de valori singulare ale matricei  $X$ , mai mari decât parametrul opțional `tol`. Acestea reprezintă un mijloc sigur pentru determinarea rangului unei matrice de formă generală. Iată câteva exemple de aplicare a funcției `rank`:

|  |   |  |
|--|---|--|
| <pre>&gt;&gt;X=[1 2 1;3 4 0;7 9 -8]</pre> <p>X =</p> <pre> 1      2      1 3      4      0 7      9     -8</pre> | <pre>&gt;&gt; r=rank(X)</pre> <pre>r =</pre> <pre> 3</pre>      | <pre>&gt;&gt; r1=rank(X,2)</pre> <pre>r1 =</pre> <pre> 2</pre>   |
|  | <pre>&gt;&gt; r2=rank(X,10)</pre> <pre>r2 =</pre> <pre> 1</pre> | <pre>&gt;&gt; r3=rank(X,100)</pre> <pre>r3 =</pre> <pre> 0</pre> |
|  |   |  |
|  |   |  |

d) Calculul valorilor singulare ale unei matrice

Numărul valorilor singulare reprezintă rangul unei matrice. Deci, calculul valorilor singulare constituie un mijloc sigur de determinare a rangului unei matrice.

Funcția `svd` se poate apela cu diferite sintaxe astfel:

`d=svd(X)`,

`[U,S,V]=svd(X)`,

sau `[U,S,V]=svd(X,0)`, pentru calcul mai rapid al valorilor singulare.

Potrivit sintaxelor de mai sus funcția returnează:

- `d` vector ce conține valorile singulare;
- `S` matrice diagonală cu dimensiunea lui  $X$  având elemente diagonale nenegative (care sunt și valorile singulare) în ordine descrescătoare;
- `U,V` matrici care satisfac relația  $X=U*S*V'$ .

```
>> X=[1 2 1;3 4 0;7 9 -8;10 3 6]

X =
     1     2     1
     3     4     0
     7     9    -8
    10     3     6

>> r=rank(X)

r =
     3

>> d=svd(X)

d =
    15.8129
    10.7584
     2.0516

>> [U,S,V]=svd(X)

U =
   -0.1154   -0.0819    0.6711   -0.7278
   -0.3028   -0.0384    0.6734    0.6733
   -0.7934    0.5610   -0.2015   -0.1232
   -0.5153   -0.8229   -0.2356   -0.0430

S =
    15.8129         0         0
         0    10.7584         0
         0         0     2.0516
         0         0         0

V =
   -0.7418   -0.4182   -0.5242
   -0.6405    0.2103    0.7386
    0.1986   -0.8837    0.4239
```

e) *Urma unei matrice*

Urma unei matrice se definește ca *suma elementelor de pe diagonala principală* și se calculează cu funcția `trace` cu sintaxa `u=trace(A)`.

De exemplu, urma matricei X folosită în exemplele anterioare este:

```
>> u=trace(X)
u =
    -3
```

iar pentru inversa ei  $Y=X^{-1}$  se obține:

```
>> u=trace(Y)
u =
-3.2667
```

### f) Calculul normelor pentru vectori și matrice

Norma este un scalar care dă o măsură (o anumită evaluare) a mărимii elementelor unui vector sau matrice. Există diferite tipuri de norme care se aplică vectorilor și matricelor și pentru care Matlab pune la dispoziție funcții specifice de evaluare, astfel:

a) Pentru matrice se pot aplica următoarele funcții:

- `norm(X)` sau `norm(X, 2)` – returnează *norma-2* reprezentând cea mai mare valoare singulară a lui X;

Din punct de vedere matematic norma-2 se definește sub forma:

$$\|X\|_2 = \sqrt{\rho(X * X)} = \max_{\lambda \in \sigma(X)} |\lambda|,$$

unde *spectrul matricei X* dat de mulțimea valorilor proprii este notat cu  $\sigma(X)$ , iar  $\rho(X)$  și  $\lambda$  sunt *raza spectrală* respectiv *valorile singulare* ale matricei X.

- `norm(X, 1)` – returnează *norma-1* denumită și *norma octaedrică*, reprezentând cea mai mare sumă a elementelor de pe coloană, adică:

$$\|X\|_1 = \max_{1 \leq j \leq N} \left( \sum_{k=1}^N |x_{jk}| \right)$$

- `norm(X, inf)` – returnează *norma infinită* reprezentând cea mai mare sumă a elementelor de pe linii, adică:

$$\|X\|_\infty = \max_{1 \leq k \leq N} \left( \sum_{j=1}^N |x_{jk}| \right)$$

- `norm(X, 'fro')` – returnează *norma-F* (Frobenius), care se calculează cu relația următoare:

$$\|X\|_F = \sqrt{\sum_{j,k=1}^N |x_{jk}|^2} = \sqrt{|x_{11}|^2 + |x_{22}|^2 + \dots + |x_{NN}|^2}$$

b) Pentru vectori se utilizează următoarele funcții:

- `norm(V, p)` returnează *norma euclidiană* și se calculează cu expresia:

$$\|V\|_p = \sqrt[p]{\sum_{k=1}^N |V_k|^p} = \sqrt[p]{|V_1|^p + |V_2|^p + \dots + |V_N|^p}$$

- `norm(V)` are același efect ca `norm(V, 2)` prin particularizarea relației de mai sus pentru  $p=2$ .
- `norm(V)/sqrt(N)` – returnează valoarea rădăcinii medii pătratice (valoare efectivă) potrivit relației următoare:

$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{k=1}^N |V_k|^2} = \sqrt{\frac{|V_1|^2 + |V_2|^2 + \dots + |V_N|^2}{N}}$$

- `norm(V, inf)` – calculează *norma maximum* (sau cubică) și returnează valoarea maximă în modul (elementul maxim în valoare absolută):

$$\|V\|_{\infty} = \max |V_k|_{1 \leq k \leq N}$$

- `norm(V, -inf)` – returnează valoarea minimă în modul (elementul minim în valoare absolută):

$$\|V\|_{-\infty} = \min |V_k|_{1 \leq k \leq N}$$

*Observație.* Funcțiile `norm(X)`, `norm(X, p)` și `norm(X, 'fro')` returnează scalari.

*Aplicație.* Să se calculeze distanța dintre punctele de coordonate A(1,2,0) și B(2,-1,5).

*Rezolvare.* Se observă că distanța dintre două puncte în sens euclidian este tocmai norma euclidiană aplicată diferenței vectorilor coordonatelor punctelor date:

$$\|V\|_2 = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

Astfel, problema se poate rezolva cu secvența de instrucțiuni următoare:

```
A =
     1     2     0

>> B=[2 -1 5]

B =
     2    -1     5

>> D=A-B

D =
    -1     3    -5

>> d=norm(D)

d =
    5.9161
```

### g) Calculul numărului de condiționare al unei matrice

#### Aspecte teoretice

Numeroase probleme ingineresti se bazează pe modele algebrice liniare. Rezultatele obținute prin calcul numeric corespund în general unei *probleme perturbate*, datorită *erorilor de rotunjire*. Astfel, dacă avem de rezolvat un sistem liniar  $A \cdot x = b$  datele A și b pot suferi perturbațiile  $\delta A$  și  $\delta b$ , inclusiv datorită erorilor de rotunjire.

În general, există însă numeroase motive de ordin tehnic în baza cărora putem considera că parametrii oricărui sistem sunt afectați de variații, ambiguitate și imprecizie. Din acest motiv este necesar a se cunoaște cât de

sensibilă este soluția unor sisteme descrise de modele liniare în raport cu variația parametrică. Aceasta se face prin evaluarea *gradului de condiționare* al problemei, pe baza teoriei matematice a perturbațiilor.

Astfel, o problemă *rău condiționată* înseamnă:

$$X \cong X^* \Rightarrow f(X) \neq f(X^*),$$

iar pentru o problemă *bine condiționată* avem:

$$X \cong X^* \Rightarrow f(X) \cong f(X^*).$$

### Exemplu aplicativ

Să se evalueze efectul proprietății de condiționare matriceală pentru o problemă de logistică modelată liniar. Fie sistemul de ecuații liniare:

$$\begin{cases} 6x_1 + 6,917x_2 = 198,34 \\ x_1 + 1,152x_2 = 33,04 \end{cases}$$

cu următoarea semnificație:

- $x_1$  – vehicule tip 1,  $x_2$  – vehicule tip 2,
- matricea coeficienților semnifică consumurile specifice celor două categorii de vehicule pe două tipuri de trasee (drum foarte greu – prima ecuație, autostradă – a doua ecuație),
- vectorul coeficienților liberi reflectă consumurile acceptate (cantitățile disponibile) repartizate pentru cele două tipuri de trasee.

Soluția problemei este:  $x_1=10, x_2=20$ .

Dacă se consideră *sistemul perturbat* (vezi a treia zecimală de la coeficientul variabilei  $x_2$ , din prima ecuație):

$$\begin{cases} 6x_1 + 6,915x_2 = 198,34 \\ x_1 + 1,152x_2 = 33,04 \end{cases}$$

soluția problemei devine:  $x_1=16,6667, x_2=33,333$ .

Se observă astfel, că o mică perturbație parametrică a sistemului a condus la diferențe considerabile asupra soluțiilor problemei. Aceasta denotă o *slabă condiționare* a problemei, fapt ce trebuie cunoscut în prealabil, deoarece poate conduce la anomalii de interpretare a rezultatelor.

Gradul de condiționare al problemei se reflectă în numărul de condiționare asociat matricei sistemului de ecuații liniare, în cazul de față al matricei:

$$A = \begin{bmatrix} 6 & 6,917 \\ 1 & 1,152 \end{bmatrix}$$

Importanța cunoașterii condiționării unei matrice decurge din faptul că rezultatele obținute prin calcul numeric corespund inevitabil unei probleme perturbate, ca urmare a efectelor erorilor de aproximare prin rotunjire.

Testarea matricelor din punct de vedere al condiționării se poate face cu ajutorul unor funcții Matlab destinate evaluării *numărului de condiționare*.

Numărul de condiționare al unei matrice indică *sensibilitatea soluției* sistemului de ecuații liniare și se definește ca *raportul dintre cea mai mare și cea mai mică valoare singulară a acesteia*. O matrice bine condiționată este o matrice relativ insensibilă la mici perturbații și reciproc o matrice slab condiționată este sensibilă la micile perturbații ale valorilor elementelor sale.

În Matlab există funcții pentru calculul numărului de condiționare al unei matrici, după cum urmează:

`c=cond(X)` – returnează raportul dintre cea mai mare valoare singulară a matricei X și cea mai mică. O valoare mare a raportului (deci a numărului de condiționare) indică o matrice aproape singulară, adică o slabă condiționare a problemei.

`c=rcond(X)` – reprezintă o funcție mai performantă ce returnează un număr de condiționare care se interpretează astfel:

- dacă  $c \approx \epsilon$  matricea X este slab condiționată,
- dacă  $c \approx 1$  matricea X este bine condiționată.

`c=condest(X)` – estimarea celui mai mic număr de condiționare.

*Observație.* Aceste funcții acceptă ca argument doar matrici pătrate (corespunzătoare sistemelor de ecuații determinate).

Revenind la exemplul dat, evaluarea numărului de condiționare al matricei A se calculează cu funcția:



$$c = rcond(A),$$

care returnează  $c = 4.7972e-005$ , valoare ce confirmă o slabă condiționare a problemei.

Celelalte funcții pentru evaluarea condiționării problemei returnează:

$$\begin{aligned} \text{cond}(A) &= 1.7234e+004 \\ \text{condest}(A) &= 2.0845e+004 \end{aligned}$$

*Exercițiu propus.* Să se verifice condiționarea următorului sistem liniar:

$$A = \begin{pmatrix} 1,2969 & 0,8648 \\ 0,2161 & 0,1441 \end{pmatrix}, \quad b = \begin{pmatrix} 0,8642 \\ 0,1440 \end{pmatrix}.$$

### 5.2.5 Descompunerea și factorizarea matricelor

În cadrul acestui capitol vom trece în revistă funcțiile Matlab specifice pentru operațiile de descompunere și factorizare a matricelor. Acestea sunt operații care se folosesc preponderent în analiza sistemelor lineare și ca metode alternative în rezolvarea sistemelor de ecuații liniare.

#### a) Valori și vectori proprii

Acestea sunt noțiuni matematice ce intervin în problemele de găsim a soluțiilor nebanale pentru sistemele de ecuații de forma:

$$F \cdot x = 0,$$

unde  $F$  este o funcție de matrice pătratică și reală, de ordinul  $n$ , conținând un parametru  $\lambda$ .

În funcție de forma lui  $F$ , problemele de valori proprii pot fi de două tipuri, astfel:

- dacă  $F = A - \lambda \cdot I$ , avem o problemă de valori proprii *liniară particulară*;
- dacă  $F = A - \lambda \cdot B$ , avem o problemă de valori proprii *liniară generală*, în care matricele  $A$  și  $B$  sunt pătrate, ( $I$  fiind matricea identitate).

În primul caz avem situația sistemului liniar  $(A - \lambda \cdot I) \cdot x = 0$  adică ecuația matriceală  $A \cdot x = \lambda \cdot x$ , unde:

A – matrice pătratică  
x – vector propriu  
 $\lambda$  – scalari, numiți valori proprii.

În cazul al doilea sistemul liniar este  $(A - \lambda \cdot B) \cdot x = 0$  adică  $A \cdot x = \lambda \cdot B \cdot x$ , unde:

A, B – matrice pătrate  
x – vector propriu generalizat  
 $\lambda$  – valori proprii generalizate

Funcția Matlab care returnează aceste valori este `eig` și este apelabilă cu una din sintaxele:

$$V = \text{eig}(A)$$

unde V – vector ce conține valorile proprii ale matricei A;

$$V = \text{eig}(A, B)$$

unde V – vector ce conține valorile proprii generalizate;

$$[V, D] = \text{eig}(A)$$

unde V – matrice ale cărei coloane sunt vectorii proprii corespunzători valorilor proprii astfel încât  $A \cdot V = V \cdot D$ ,

D – matrice diagonală care conține valorile proprii ale matricei A;

$$[V, D] = \text{eig}(A, B)$$

respectiv

$$[V, D] = \text{eig}(A, 'nobalance'),$$

în care 'nobalance' este o opțiune ce anulează *scalarea* valorilor elementelor mici ale matricei A (comparabile cu erorile de rotunjire) și considerarea lor la fel de semnificativă ca și celelalte elemente – lucru care ar conduce la vectori proprii incorecți.

În continuare se dau câteva exemple numerice pentru lucrul cu valori și vectori proprii.

```
>> A=[6 6.917;1 1.152]
```

```
A =
    6.0000    6.9170
    1.0000    1.1520
```

```
>> V=eig(A)
```

```
V =
    7.1527
   -0.0007
```

```
>> [V,D]=eig(A)
```

```
V =
    0.9864   -0.7554
    0.1644    0.6553
```

```
D =
    7.1527    0
         0   -0.0007
```

```
>> [V,D]=eig(A,'nobalance')
```

```
V =
    1.0000   -1.0000
    0.1666    0.8675
```

```
D =
    7.1527    0
         0   -0.0007
```

```
>> B=randn(2)
```

```
B =
   -0.4326    0.1253
   -1.6656    0.2877
```

```
>> V1=eig(A,B)
```

```
V1 =
   -0.0004
  149.7197
```

```
>> [V,D]=eig(A,B)
```

```
V =
    1.0000   -0.1674
   -0.8674   -1.0000
```

```
D =
   -0.0004    0
         0  149.7197
```

### b) Factorizarea Cholesky

Factorizarea unei matrice  $A$  constă în descompunerea ei de forma  $R^t \cdot R = A$  unde  $R$ , numit *factorul Cholesky* este o matrice unică, superior triunghiulară și nesingulară.

Factorizarea Cholesky este o metodă directă de rezolvare a unui sistem de ecuații liniare de forma  $A \cdot x = b$ , cu condiția ca matricea  $A$  să fie pozitiv definită, adică:  $A = A^t$  și  $\det(A) > 0$ . Prin urmare, dacă se factorizează în sens Cholesky matricea coeficienților sistemului  $A$ , ecuația matriceală ce descrie sistemul devine:

$$R^t \cdot R \cdot x = b,$$

iar soluția acesteia se obține prin rezolvarea succesivă a sistemelor:  $R^t \cdot y = b$  și apoi  $R \cdot x = y$ .

Funcția Matlab pentru factorizarea Cholesky se apelează cu sintaxele:

```
R=chol (A);
[R,p]=chol (A);
```

unde  $A$  – o matrice (pozitiv definită)

$R$  – o matrice superior triunghiulară, astfel încât  $R' * R = A$

$p$  – un scalar de test, egal cu zero dacă matricea  $A$  este pozitiv definită și un întreg pozitiv în caz contrar.

*Exemplu.* Rezolvarea unui sistem de ecuații liniare în Matlab pe baza factorizării Cholesky cu forma  $R' * R * x = b$  se va efectua parcurgând următoarele etape:

- se rezolvă sistemul  $R' \cdot y = b$  cu instrucțiunea  $y = R' \setminus b$ ;
- se rezolvă sistemul  $R \cdot x = y$  cu instrucțiunea  $x = R \setminus y$ .

Aceste etape se rezolvă cu instrucțiunile:

```
R=chol (A),
X=R \ (R' \ b)
```

```
>> A=[10 -1 1; -1 5 0; 1 0 10]
A =
    10    -1     1
    -1     5     0
     1     0    10

>> b'=[10 -5 0]
b =
    10
    -5
     0

>> [R,p]=chol (A)
R =
    3.1623    -0.3162     0.3162
         0     2.2136     0.0452
         0         0     3.1461

p =
     0

>> x=R \ (R' \ b)
x =
    0.9278
   -0.8144
   -0.0928
```

#### Verificare

```
>> b=A*x
b =
    10
    -5
     0
```

c) Factorizarea LU (lower-upper)

Acest tip de factorizare realizează o descompunere a unei matrici pătrate ca produs a două matrice triunghiulare: una inferior triunghiulară, cu elemente 1 pe diagonala principală (matricea L) și cealaltă superior triunghiulară (matricea U).

Sintaxe de apelare:

$$[L, U] = \text{lu}(X),$$

returnează o matrice superior triunghiulară U și o matrice inferior triunghiulară permutată L, astfel încât  $X = L * U$ ;

$$[L, U, P] = \text{lu}(X),$$

furnizează o matrice superior triunghiulară U, o matrice inferior triunghiulară L și permutarea matriceală P, astfel încât  $L * U = P * X$ .

Notă. În Matlab factorizarea LU este utilizată pentru calculul inversei și determinantului în cadrul algoritmului funcției `inv`, respectiv `det`. De asemenea, acest tip de factorizare constituie baza rezolvării sistemelor de ecuații liniare prin împărțire matriceală cu operatorii `\` și `/`, astfel:

- inversa unei matrice se poate calcula cu:  $X = \text{inv}(U) * \text{inv}(L)$ ;
- determinantul se calculează cu:  $D = \text{det}(L) * \text{det}(U)$ ;
- rezolvarea sistemelor de ecuații liniare  $A \cdot x = b$  prin factorizarea LU presupune soluționarea succesivă a sistemelor:  $y = L \backslash b$  și  $x = U \backslash y$  cu instrucțiunile:  $[L, U] = \text{lu}(A)$  și  $x = U \backslash (L \backslash b)$ .

d) Factorizarea QR

Factorizarea QR este o descompunere a unei matrici ca produs între o matrice ortonormală Q (adică  $Q^t \cdot Q = I$ ) și o matrice superior triunghiulară R. Se mai numește *descompunerea ortogonal-triunghiulară* și se realizează cu funcția `qr` apelată cu una dintre sintaxele:

$$\begin{aligned} [Q, R] &= \text{qr}(X), \\ [Q, R, E] &= \text{qr}(X), \end{aligned}$$

unde: R – matrice superior triunghiulară de aceeași dimensiune ca X;

Q – matrice ortogonală;

E – matricea permutată a matricei superior triunghiulară R cu elementele diagonalei descrescătoare astfel încât:  $X * E = Q * R$ , iar  $\text{triu}(\text{qr}(X)) = R$ .

*Notă.* Acest tip de factorizare se folosește pentru rezolvarea sistemelor de ecuații liniare supradeterminate (care au mai multe ecuații decât necunoscute). Prin utilizarea factorizării QR soluția sistemului este calculată în doi pași:

$$y = Q' * b$$

$$x = R \backslash y$$

*Exemplu.* Fie sistemul supradeterminat descris de matricea  $A = \begin{bmatrix} 10 & 2 & 1 \\ -1 & 5 & 0 \\ 1 & 0 & 10 \\ -2 & 3 & 7 \end{bmatrix}$  și vectorul termenilor liberi  $b = [10 \ 5 \ 0 \ 1]$ . Să se determine o soluție a sistemului folosind factorizarea QR potrivit secvenței de instrucțiuni:

$$[Q, R] = \text{qr}(A)$$

$$x = R \backslash (Q' * b)$$

```
>> A=[10 2 1 ; -1 5 0 ; 1 0 10 ; -2 3 7]

A =
    10     2     1
    -1     5     0
     1     0    10
    -2     3     7

>> b=[10 5 0 1]

>> b=b'

b =
    10
     5
     0
     1

>> [Q,R]=qr(A)

Q =
   -0.9713   -0.1886    0.0224    0.1433
    0.0971   -0.8333    0.2584   -0.4789
   -0.0971    0.0139   -0.8568   -0.5062
    0.1943   -0.5195   -0.4457    0.7027

R =
  -10.2956   -0.8742   -0.5828
         0   -6.1021   -3.6857
         0         0  -11.6652
         0         0         0

>> x=R \ (Q' * b)

x =
    0.7864
    1.1324
   -0.0918
```

#### Verificare

```
>> b=A*x

b =

    10.0371
     4.8758
    -0.1312
     1.1822
```

e) Pseudoinversa unei matrice sau inversa generalizată Moore-Penrose

Pseudoinversa unei matrice se utilizează, de regulă, pentru rezolvarea sistemelor de ecuații liniare supradeterminate, în sensul *celor mai mici pătrate*. Aceasta se calculează cu funcția `pinv` cu sintaxa:

$$X = \text{pinv}(A),$$

returnând matricea pseudoinversă  $X$  care are aceeași dimensiune ca și matricea  $A^t$ . Matricea pseudoinversă  $X$  a unei matrice  $A$  verifică relațiile:  $A * X * A = A$  și  $X * A * X = X$ .

*Exemplu.* Fie  $A \cdot x = B$  un sistem supradeterminat cu  $A(4 \times 3)$  și  $B(4 \times 1)$ . Să se afle o soluție cu ajutorul pseudoinversei.

```
>> A=[10 2 1 ; -1 5 0 ; 1 0 10 ; -2 3 7]

A =
    10     2     1
    -1     5     0
     1     0    10
    -2     3     7

>> b=[10 5 0 1]

b =
    10     5     0     1

>> b=b'

b =
    10
     5
     0
     1

>> X=pinv(A)

X =
    0.0917   -0.0209    0.0092   -0.0263
    0.0321    0.1499   -0.0466    0.0621
   -0.0019   -0.0222    0.0734    0.0382

>> x=X*b'

x =
    0.7864
    1.1324
   -0.0918
```